La Causal AI pour les nuls

La Causal AI cherche à répondre à « qu'est-ce qui se passerait si on changeait X ? », là où le machine learning classique répond seulement à « qu'est-ce qui va avec X ? ». Ce guide en explique les idées sans prérequis, avec des exemples tirés de la santé.

1. Corrélation n'est pas causalité

Deux choses peuvent varier ensemble sans que l'une provoque l'autre.

- **Les glaces et les noyades.** Les jours où l'on vend le plus de glaces sont aussi ceux où il y a le plus de noyades. Les glaces ne font pas couler les nageurs : c'est la chaleur qui pousse à la fois à acheter des glaces et à se baigner.
- **Les médicaments contre le diabète.** Les personnes qui en prennent ont plus de sucre dans le sang que les autres. Le médicament ne fait pas monter le sucre : ces personnes sont diabétiques, et c'est justement pour cela qu'on le leur a prescrit.

Dans les deux cas, un **troisième facteur** (la chaleur, le diabète) explique l'association. On l'appelle un *facteur de confusion*.

Un modèle de machine learning classique apprend ces associations sans distinguer cause et coïncidence. Il prédit bien, mais il ne dit pas ce qui se passerait si l'on agissait : interdire les glaces ne réduirait pas les noyades. La Causal AI regroupe les méthodes qui répondent à cette question d'action.

2. La question « et si ? » : le contrefactuel

Un effet causal est une comparaison entre deux mondes : celui où la personne prend le médicament et celui où elle ne le prend pas.

On note **Y(1)** le résultat si la personne est traitée et **Y(0)** le résultat si elle ne l'est pas. Ce sont les *résultats potentiels*. L'effet du traitement pour cette personne est la différence $Y(1) - Y(0)$.

Le problème fondamental : on n'observe jamais les deux mondes pour la même personne. Si Paul prend son médicament, on voit son résultat sous traitement, mais on ne saura jamais ce qu'il aurait été sans. La valeur manquante s'appelle le *contrefactuel*.

La solution : renoncer à l'effet individuel exact et estimer un effet **moyen**, en comparant des groupes de personnes traitées et non traitées qui se ressemblent sur tout le reste (âge, maladies, mode de vie).

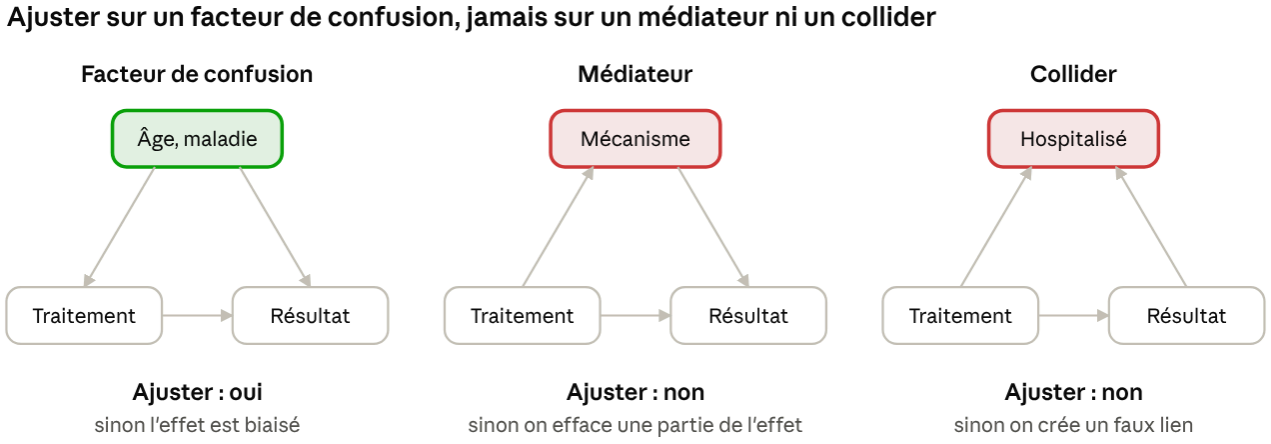
Quantité	Question	Abréviation
Effet moyen	En moyenne dans la population, de combien le médicament change-t-il le résultat ?	ATE
Effet chez les traités	Pour ceux qui le prennent réellement, quel effet ?	ATT
Effet conditionnel	Pour une personne de 70 ans, diabétique, quel effet ?	CATE

Un essai clinique randomisé résout le problème par le hasard : le tirage au sort rend les deux groupes comparables. Sans tirage au sort, avec des données d'observation, il faut recréer cette comparabilité par le calcul : c'est tout l'objet de la Causal AI.

3. Dessiner ses hypothèses : le graphe causal

Avant tout calcul, on dessine ce que l'on sait du problème : chaque flèche dit « A influence B ». Ce dessin s'appelle un *graphe causal* (ou DAG, pour *Directed Acyclic Graph*). Il ne se déduit pas des données : il vient des connaissances médicales, et c'est lui qui dit sur quelles variables ajuster.

Trois structures reviennent partout, et chacune demande un traitement différent.



les trois structures de base d'un graphe causal

- **Facteur de confusion** (âge, maladie) : il influence à la fois le traitement et le résultat. Il **faut** en tenir compte, sinon l'effet est faux.
- **Médiateur** : c'est le chemin par lequel le traitement agit (un diurétique fait uriner, ce qui fait baisser le sodium). Il **ne faut pas** ajuster dessus, sinon on efface une partie de l'effet que l'on cherche.

- **Collider** (ou variable de collision) : il est causé à la fois par le traitement et par le résultat, par exemple le fait d'être hospitalisé. Ajuster dessus, ou ne garder que ces personnes, **crée** une fausse association.

La règle qui en découle s'appelle le **critère backdoor** : il faut ajuster sur un ensemble de variables qui bloque tous les chemins « par la porte de derrière » entre traitement et résultat (ceux qui passent par un facteur de confusion), sans inclure ni médiateur ni collider.

4. Les trois conditions pour pouvoir conclure

Une estimation causale à partir de données d'observation n'est valable que si trois conditions sont réunies.

Condition	En clair	Exemple de violation
Échangeabilité (pas de confusion cachée)	Une fois qu'on a tenu compte des facteurs mesurés, traités et non-traités sont comparables	La gravité de la maladie n'est pas mesurée alors qu'elle décide du traitement
Positivité	Pour chaque profil, il existe à la fois des personnes traitées et non traitées	Tous les diabétiques de plus de 70 ans prennent le médicament : aucun point de comparaison
Cohérence	Le traitement est bien défini et le même pour tous	« Prendre un diurétique » regroupe des doses et des molécules très différentes

La première ne se vérifie jamais complètement avec les données : c'est pourquoi on teste ensuite la robustesse des résultats (section 6).

5. Les méthodes d'estimation

Toutes les méthodes cherchent à comparer des traités et des non-traités qui se ressemblent. Elles diffèrent par la façon de rendre les groupes comparables.

Méthode	Idée	Point fort	Point faible
Ajustement par régression	Modéliser le résultat en fonction du traitement et des facteurs de confusion	Simple, rapide	Faux si le modèle est mal spécifié
Score de propension	Calculer pour chacun sa probabilité d'être traité, puis comparer des personnes de score proche (appariement)	Résume des dizaines de variables en un seul nombre	Perd les personnes sans « jumeau »
Pondération (IPW)	Donner plus de poids aux personnes « rares » (traitées alors qu'elles avaient peu de chances de l'être) pour créer une population fictive où le traitement est distribué au hasard	Garde tout l'échantillon	Instable si certains poids sont énormes
Doublement robuste (AIPW)	Combiner un modèle du résultat et un score de propension	Reste juste si l'un des deux modèles est bon	Un peu plus complexe
Double machine learning (DML)	Utiliser des modèles de machine learning pour « retirer » l'influence des facteurs de confusion, puis estimer l'effet sur ce qui reste	Gère beaucoup de variables et des relations non linéaires	Demande plus de données
Forêts causales	Variante des forêts aléatoires qui estime un effet différent selon le profil	Donne l'effet personnalisé (CATE)	Plus lente, plus dure à interpréter

En pratique, on commence par une méthode simple, puis on vérifie que les méthodes plus avancées donnent un résultat proche.

6. Vérifier ses résultats

Comme on ne peut jamais prouver qu'il ne reste aucune confusion cachée, on soumet le résultat à des tests qu'il doit passer s'il est fiable.

- **Tests de réfutation.** On « sabote » volontairement l'analyse pour voir si elle réagit comme prévu. Remplacer le vrai traitement par un traitement tiré au hasard (*placebo*) doit donner un effet nul. Ajouter une variable aléatoire comme facteur de confusion ne doit pas changer le résultat. Refaire l'analyse sur des sous-échantillons doit donner à peu près la même chose.
- **Témoins positifs et négatifs.** On applique la méthode à des cas dont on connaît déjà la réponse : un effet bien documenté doit être retrouvé (témoin positif), et un couple médicament-résultat sans lien connu doit donner un effet nul (témoin négatif). Si la méthode trouve un effet là où il n'y en a pas, c'est qu'il reste un biais.
- **E-value.** Elle répond à la question : « quelle force devrait avoir un facteur de confusion caché pour annuler complètement mon résultat ? ». Une E-value élevée signifie qu'il faudrait un facteur caché très puissant : le résultat est solide.

7. Les outils Python

Outil	À quoi il sert	Lien
DoWhy	La démarche complète en 4 étapes : modéliser (le graphe), identifier (sur quoi ajuster), estimer, réfuter	Documentation · GitHub
EconML	Les estimateurs avancés : double machine learning, forêts causales, effets personnalisés	GitHub

Les deux font partie de l'écosystème PyWhy et s'utilisent ensemble : DoWhy organise l'analyse et peut appeler les estimateurs d'EconML.

8. Glossaire

Terme	Définition
Traitement (T)	Ce dont on veut mesurer l'effet : ici, prendre ou non une classe de médicament
Résultat (Y)	Ce sur quoi on mesure l'effet : par exemple, le taux de sodium
Facteur de confusion	Variable qui influence à la fois le traitement et le résultat
Résultats potentiels	Les résultats qu'aurait une personne avec et sans traitement, Y(1) et Y(0)

Terme	Définition
Contrefactuel	Le résultat qu'on n'observe pas : ce qui se serait passé dans l'autre scénario
ATE / ATT / CATE	Effet moyen dans la population / chez les traités / pour un profil donné
Graphe causal (DAG)	Dessin des liens de cause à effet supposés entre les variables
Critère backdoor	Règle qui dit sur quelles variables ajuster pour bloquer la confusion
Médiateur	Variable par laquelle passe l'effet du traitement
Collider	Variable causée à la fois par le traitement et le résultat, sur laquelle il ne faut pas ajuster
Score de propension	Probabilité d'être traité compte tenu de son profil
Positivité	Chaque profil a une chance d'être traité et de ne pas l'être
Réfutation	Test qui vérifie que le résultat résiste à un sabotage volontaire de l'analyse
E-value	Force minimale d'une confusion cachée capable d'annuler le résultat

Sources

Pour débuter

- Pearl J., Mackenzie D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books. Vulgarisation par l'inventeur des graphes causaux. Présentation
- Facure M. *Causal Inference for the Brave and True*. Livre en ligne avec code Python, très pédagogique. Lire en ligne
- Neal B. (2020). *Introduction to Causal Inference from a Machine Learning Perspective*. Cours et vidéos. Cours · PDF
- Cunningham S. (2021). *Causal Inference: The Mixtape*. Yale University Press. Site du livre

Référence du domaine (santé)

- Hernán M. A., Robins J. M. *Causal Inference: What If*. Chapman & Hall/CRC. Le manuel de référence en épidémiologie, gratuit en PDF. Livre

Articles fondateurs

- Rosenbaum P. R., Rubin D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1), 41–55. PDF
- Lipsitch M., Tchetgen Tchetgen E., Cohen T. (2010). Negative controls: a tool for detecting confounding and bias in observational studies. *Epidemiology*. Article
- VanderWeele T. J., Ding P. (2017). Sensitivity analysis in observational research: introducing the E-value. *Annals of Internal Medicine*. DOI · PDF
- Chernozhukov V. et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1). arXiv

Outils

- Sharma A., Kiciman E. (2020). DoWhy: An end-to-end library for causal inference. arXiv · Documentation
- EconML (Microsoft Research, PyWhy). GitHub