Les traitements expliquent-ils ce résultat d'analyse ? Inférence causale des effets médicamenteux sur les biomarqueurs (NHANES 2005–2018)

Nov 4, 2026 ·

Description of Work — PER MAM5 mineure Science des Données, Polytech Nice Sophia, 2026-2027. Thématique : Causal AI. Brouillon.

Page de garde

- **Titre** : Les traitements expliquent-ils ce résultat d'analyse ? Inférence causale des effets médicamenteux sur les biomarqueurs à partir de NHANES
- **Étudiants** :
- **Formation** :
- **Encadrant** :

1. Objectif général du projet

Le projet développe un outil qui estime, pour un patient et un résultat d'analyse donnés, quelle part de ce résultat est causée par chacun de ses traitements.

Problème métier. Devant une valeur biologique anormale (manque de sodium dans le sang, excès de potassium, signe de fatigue des reins ou du foie), le pharmacien clinicien ou le pharmacovigilant doit déterminer si un médicament est en cause. Cette démarche d'imputabilité repose aujourd'hui sur des critères qualitatifs (chronologie, arrêt et reprise du traitement) et sur la littérature. Elle ne quantifie pas l'effet propre du médicament.

Limite des approches actuelles. Les effets d'un médicament sur un résultat d'analyse sont connus en moyenne, par les essais cliniques et les notices, mais rarement chiffrés pour un profil de patient donné : âge, pathologies, autres traitements. Les bases de déclarations d'effets indésirables ne comblent pas ce manque, car elles ne recensent que les cas signalés, sans comparaison avec des patients non traités. Elles permettent de repérer un problème, pas de mesurer l'ampleur de l'effet.

Ce que le projet apporte. À partir d'une enquête de santé en population générale, l'outil estime l'effet causal de chaque classe de médicament (groupe de médicaments qui agissent de la même façon, par exemple les diurétiques) sur un biomarqueur (valeur mesurée dans le sang, comme le sodium ou le glucose), ajusté sur les facteurs de

confusion (caractéristiques comme l'âge ou une maladie, qui influencent à la fois la prise du médicament et le résultat d'analyse). Pour un profil donné, il restitue la valeur attendue sans le traitement et la part de l'écart attribuable au traitement. C'est une aide à l'investigation, pas un outil de diagnostic.

Utilisateurs visés : pharmacovigilants, pharmaciens cliniciens (revue de médication), équipes de sécurité des médicaments en industrie.

2. Données utilisées

Le projet utilise NHANES (*National Health and Nutrition Examination Survey*, CDC), une enquête de santé représentative de la population américaine, en libre accès et sans restriction de diffusion. Nous retenons les 7 cycles bisannuels de 2005–2006 à 2017–2018, déjà téléchargés, harmonisés et chargés dans PostgreSQL.

Bloc	Fichiers NHANES	Contenu	Rôle dans le projet
Démographie	DEMO	Âge, sexe, origine, revenus, études, poids de sondage	Facteurs de confusion, pondération
Examen	BMX, BPX	IMC, poids, tour de taille, pression artérielle	Facteurs de confusion
Laboratoire	BIOPRO, GHB, CBC, TCHOL, HDL, TRIGLY	Sodium, potassium, créatinine, urée, acide urique, glucose, ALAT, ASAT, GGT, HbA1c, lipides, NFS	Variables d'issue (Y)
Questionnaires	MCQ, DIQ, BPQ, KIQ_U, SMQ, ALQ	Pathologies déclarées (diabète, HTA, insuffisance cardiaque et rénale, hépatopathie, cancer), tabac, alcool	Facteurs de confusion, indications
Médicaments	RXQ_RX, RXQ_DRUG	Médicaments sur ordonnance des 30 derniers jours, durée de prise, classe thérapeutique (Multum)	Traitements (T)

Volumes. 70 190 participants, 533 variables, 95 657 lignes de médicaments. La population d'analyse sera restreinte aux adultes (18 ans et plus) ayant un bilan biologique, soit de l'ordre de 35 000 à 40 000 personnes (effectif exact à confirmer).

Structure. Deux tables dans PostgreSQL : `nhanes.participants` (une ligne par participant, clé `seqn`) et `nhanes.medicaments` (une ligne par médicament déclaré). Un dictionnaire généré à partir des libellés officiels du CDC décrit chaque colonne. Les scripts de téléchargement, d'harmonisation et de chargement rendent la base reproductible.

Prétraitements prévus.

- Harmonisation entre cycles : noms de fichiers, variables présentes dans tous les cycles, recalibration de la créatinine pour les cycles concernés.
- Poids de sondage combinés (poids sur 2 ans divisé par 7), avec un poids spécifique pour le sous-échantillon à jeun (LDL, triglycérides).
- Traitements codés en indicateurs binaires par classe thérapeutique (30 à 50 classes les plus fréquentes).
- Codes « refus » et « ne sait pas » (7, 9, 77, 99) traités comme manquants ; imputation multiple ou analyse en cas complets selon la part de manquants.

Limites connues. Les données sont transversales : le traitement et l'analyse sont mesurés au même moment. La durée de prise déclarée sert de garde-fou sur la temporalité. Les doses ne sont pas renseignées, et les classes de médicaments rares auront des effectifs trop faibles pour être étudiées.

3. Thématique choisie : Causal AI

La question du projet est causale par nature : « quelle serait la valeur de ce biomarqueur si le patient ne prenait pas ce médicament ? ». Un modèle prédictif classique y répond mal, car il apprend des associations, pas des effets.

Pourquoi la corrélation ne suffit pas. Les médicaments sont prescrits à des patients déjà malades : c'est la *confusion par indication*. Les personnes qui prennent un médicament contre le diabète ont une glycémie plus élevée que le reste de la population : ce n'est pas le médicament qui fait monter leur taux de sucre, c'est qu'elles sont diabétiques. De même, les personnes sous traitement contre l'hypertension ont en moyenne une tension plus élevée que les autres, parce qu'elles sont hypertendues. Une simple corrélation conclurait à tort que ces médicaments font monter le sucre ou la tension. La Causal AI fournit le cadre pour corriger ce biais : un graphe causal explicite, des hypothèses d'identification vérifiables, des estimateurs adaptés et des tests de réfutation.

Lien entre la thématique et les données. Chaque exigence de l'inférence causale trouve une réponse dans NHANES, ce qui justifie le choix de ce jeu de données.

Exigence de l'inférence causale	Réponse dans NHANES
Comparer exposés et non-exposés	Population générale, avec et sans chaque traitement
Mesurer les facteurs de confusion	Âge, sexe, IMC, revenus, tabac, alcool, pathologies déclarées
Mesurer l'issue sans biais de déclaration	Biomarqueurs dosés en laboratoire pour tous
Positivité (chaque profil peut être traité ou non)	À vérifier par classe ; vérifiable grâce aux effectifs
Représentativité	Poids de sondage et plan d'échantillonnage
Validation sur des effets connus	Effets documentés médicament → biomarqueur (témoins positifs)

D'autres jeux de données ont été explorés en amont du projet, mais aucun ne répondait de façon satisfaisante à ces exigences.

La principale limite reste le caractère transversal des données : la temporalité est supposée (traitement pris avant la mesure) et contrôlée par la durée de prise.

4. État de l'art

Le projet se situe à la jonction de trois domaines matures, sans outil existant qui les combine pour l'attribution individuelle d'un résultat biologique.

Détection de signaux en pharmacovigilance. Les autorités exploitent les notifications spontanées par des mesures de disproportionnalité : PRR [Evans 2001], ROR, BCPNN de l'OMS [Bate 1998] et MGPS de la FDA [DuMouchel 1999]. Elles génèrent des hypothèses mais ne quantifient pas un effet causal. L'imputabilité d'un cas reste évaluée par des échelles qualitatives [Naranjo 1981].

Pharmaco-épidémiologie observationnelle. L'estimation d'effets causaux à partir de données de soins repose sur le score de propension [Rosenbaum & Rubin 1983], l'émulation d'essai cible [Hernán & Robins 2016] et, à grande échelle, sur le réseau OHDSI (étude LEGEND-HTN [Schuemie 2019]). Ces travaux ont formalisé l'usage de témoins négatifs [Lipsitch 2010] et la calibration empirique [Schuemie 2014], que nous reprenons pour la validation. NHANES est déjà utilisé pour des effets médicament → biomarqueur précis, par exemple la carence en B12 sous metformine [Reinstatler 2012], mais toujours une question à la fois.

Causal machine learning. Le *double machine learning* [Chernozhukov 2018], les forêts causales [Wager & Athey 2018] et les méta-apprenants [Künzel 2019] estiment des effets moyens et hétérogènes avec des modèles flexibles. Les bibliothèques DoWhy [Sharma & Kiciman 2020] et EconML [Battocchi 2019] (Microsoft, sur GitHub) les rendent accessibles et ajoutent des tests de réfutation. Les exemples publiés portent surtout sur l'économie et le marketing.

Positionnement.

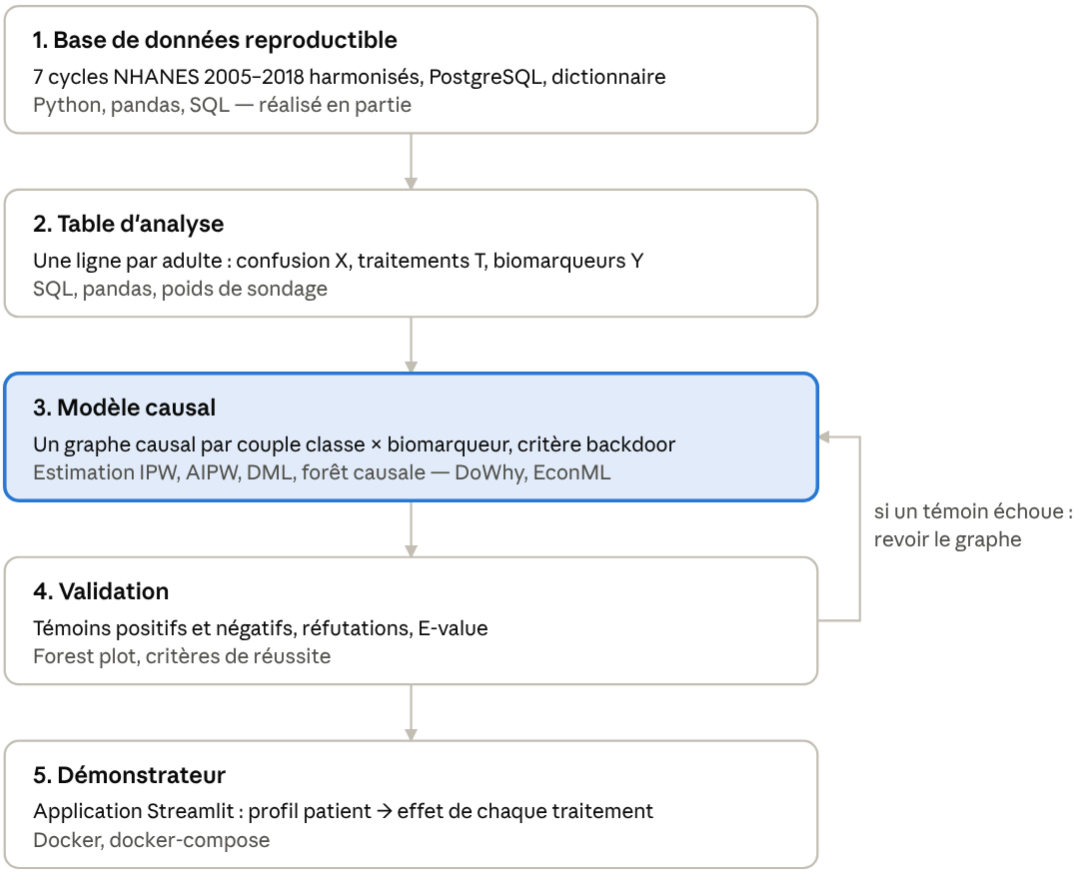
Approche existante	Ce qu'elle fait	Ce que le projet ajoute
Disproportionnalité sur notifications spontanées	Détecte des signaux dans les cas déclarés	Un effet causal estimé en population générale
Études NHANES publiées	Un couple médicament → biomarqueur par article	Un cadre générique pour 30 à 50 classes et une quinzaine de biomarqueurs
OHDSI / LEGEND	Effets moyens sur de grandes bases de soins (accès restreint)	Des effets conditionnels au profil, sur données ouvertes
DoWhy / EconML	Outils génériques d'estimation	Une application de pharmacovigilance validée sur témoins positifs et négatifs, avec un démonstrateur

Références à vérifier (années, revues) avant la version finale.

5. Objectifs techniques du projet

Le projet s'articule en cinq briques, de la base de données au démonstrateur.

Chaque estimation est validée sur des effets connus avant le démonstrateur



pipeline du projet · 5 briques, 1 boucle de validation

1. **Base de données reproductible** (réalisée en partie) : téléchargement automatique des fichiers CDC, harmonisation des 7 cycles, chargement dans PostgreSQL, dictionnaire des variables.
2. **Table d'analyse** : une ligne par adulte, avec les facteurs de confusion (X), les indicateurs de traitement par classe (T), les biomarqueurs (Y), les poids et le plan de sondage. Requêtes SQL et pandas.
3. **Modèle causal** : un graphe causal type, décliné pour chaque couple classe × biomarqueur, avec l'indication de la classe comme facteur de confusion. Identification par le critère *backdoor* avec DoWhy, puis estimation :
   - effet moyen par pondération inverse (IPW) et estimateur doublement robuste (AIPW) ;
   - *double machine learning* (EconML `LinearDML`) avec des modèles de nuisance en gradient boosting ;
   - effet conditionnel au profil (CATE) par forêt causale (EconML `CausalForestDML`).
4. **Validation** :

- **témoins positifs** : environ 8 effets documentés (thiazidiques → potassium et sodium ↓, IEC et spironolactone → potassium ↑, statines → LDL ↓, allopurinol → acide urique ↓, corticoïdes → glucose ↑, ISRS → sodium ↓, metformine → B12 ↓, si le dosage de B12 est ajouté pour les cycles où il existe) ;
- **témoins négatifs** : couples sans effet connu, pour mesurer le biais résiduel ;
- **réfutations DoWhy** : traitement placebo, cause commune aléatoire, sous-échantillons ;
- **sensibilité** à une confusion non mesurée (E-value).

5. **Démonstrateur** : application Streamlit conteneurisée avec Docker (section 8).

Critères de réussite. L'estimation ajustée retrouve le sens attendu pour au moins 7 témoins positifs sur 8, les témoins négatifs ont un intervalle de confiance qui contient 0 dans au moins 90 % des cas, et l'ajustement réduit l'écart observé entre corrélation brute et effet attendu sur les cas de confusion par indication (allopurinol, IEC).

6. Étude théorique : identifier et estimer un effet causal à partir de données observationnelles

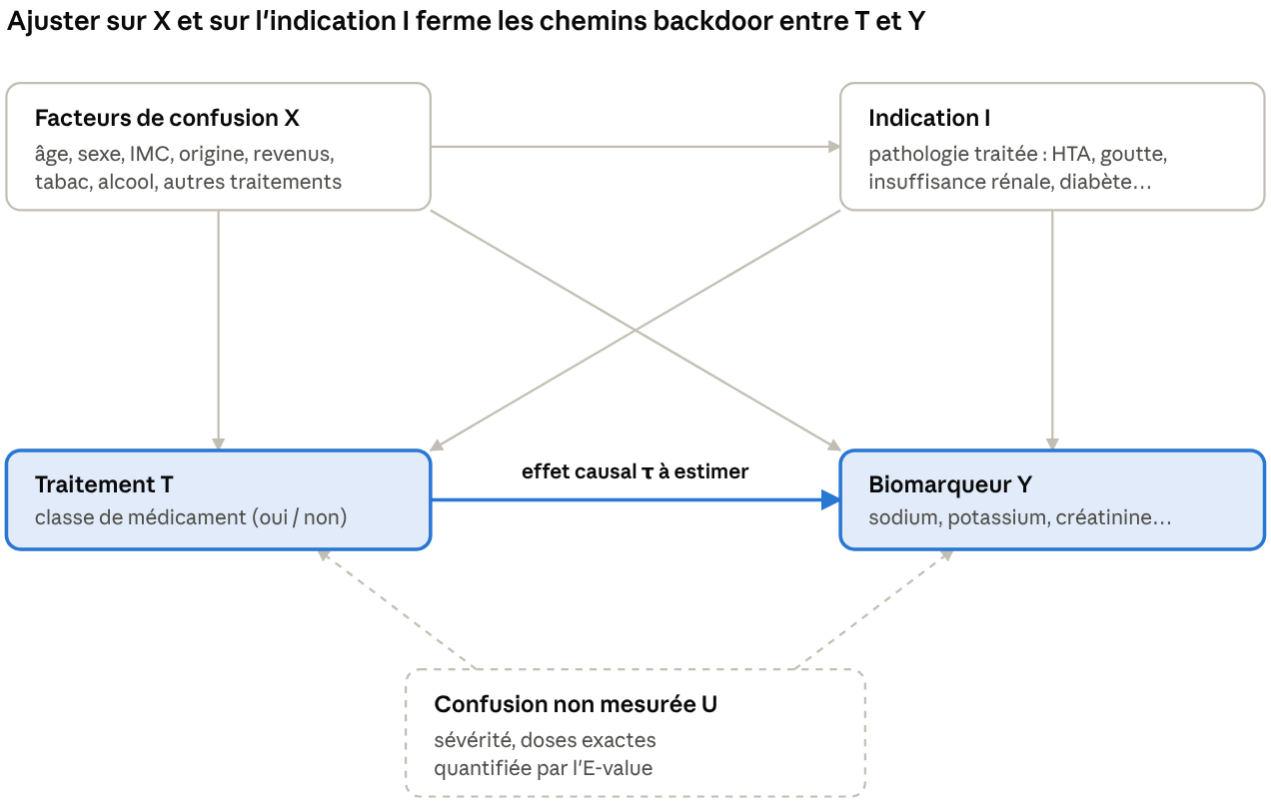
L'étude théorique porte sur les conditions sous lesquelles un effet médicament → biomarqueur est identifiable dans NHANES, et sur les estimateurs qui l'estiment sans biais.

6.1 Cadre des résultats potentiels. Pour un individu i, on note T le traitement (1 = prend la classe, 0 = ne la prend pas), Y(1) et Y(0) les valeurs du biomarqueur dans les deux situations, et X les facteurs de confusion. Les quantités d'intérêt sont l'effet moyen (ATE), l'effet moyen chez les traités (ATT) et l'effet conditionnel au profil (CATE) :

```
\tau = \mathbb{E}[Y(1) - Y(0)], \qquad \tau_{ATT} = \mathbb{E}[Y(1) - Y(0)
\mid T = 1], \qquad \tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]
```

6.2 Identification. Seul l'un des deux résultats potentiels est observé. L'effet est identifiable sous trois hypothèses : cohérence (Y = Y(T)), échangeabilité conditionnelle (pas de confusion non mesurée une fois X connu) et positivité (0 < P(T = 1 | X) < 1). Le graphe causal ci-dessous rend la deuxième hypothèse explicite : X doit bloquer tous les chemins *backdoor* entre T et Y (critère de Pearl), sans contenir de médiateur ni de *collider*. On obtient alors :

```
\mathbb{E}[Y(t)] = \mathbb{E}_X\big[\, \mathbb{E}[Y \mid T = t, X] \,\big]
```



graphe causal type · 5 nœuds, l'effet T → Y à estimer

Les flèches pleines sont des chemins de confusion, bloqués en ajustant sur X et I ; la flèche colorée est l'effet estimé ; les flèches pointillées représentent une confusion non mesurée, traitée par analyse de sensibilité.

6.3 Estimation doublement robuste. L'estimateur AIPW combine un modèle de l'issue $\mu_t(X)$ et un score de propension $e(X) = P(T = 1 \mid X)$. Il reste sans biais si l'un des deux modèles est correct :

$$\hat\tau_{AIPW} = \frac{1}{n}\sum_{i=1}^{n}\left[\hat\mu_1(X_i) - \hat\mu_0(X_i) + \frac{T_i\,(Y_i - \hat\mu_1(X_i))}{\hat e(X_i)} - \frac{(1 - T_i)\,(Y_i - \hat\mu_0(X_i))}{1 - \hat e(X_i)}\right]$$

Le *double machine learning* généralise cette idée au modèle partiellement linéaire $Y = \theta T + g(X) + \varepsilon$, $T = m(X) + \eta$. On estime g et m par apprentissage automatique avec validation croisée (*cross-fitting*), puis θ par régression des résidus. L'orthogonalité de Neyman garantit que les erreurs des modèles de nuisance n'affectent θ qu'au second ordre :

$$\hat\theta = \frac{\sum_i \big(T_i - \hat m(X_i)\big)\big(Y_i - \hat\ell(X_i)\big)}{\sum_i \big(T_i - \hat m(X_i)\big)^2}, \qquad \ell(X) = \mathbb{E}[Y \mid X]$$

Nous étudierons les propriétés asymptotiques de ces estimateurs, le rôle du *cross-fitting*, et l'intégration des poids de sondage NHANES.

6.4 Du niveau population au patient. Pour un patient traité de profil x_i et de valeur observée Y_i, le démonstrateur restitue la valeur contrefactuelle estimée et la part de l'écart à la valeur de référence y_ref attribuable au traitement :

```
\hat Y_i(0) = Y_i - \hat\tau(x_i), \qquad \text{part attribuable} =
\frac{\hat\tau(x_i)}{Y_i - y_{ref}}
```

Cette quantité est un déplacement moyen pour des patients de même profil. La causalité au niveau d'un individu (le médicament a-t-il causé *son* résultat ?) n'est pas identifiable sans hypothèses supplémentaires : l'étude théorique précisera cette limite et la manière de la communiquer.

6.5 Sensibilité. L'E-value [VanderWeele & Ding 2017] mesure la force qu'une confusion non mesurée devrait avoir pour annuler l'effet estimé. Elle sera reportée pour chaque effet.

7. Adéquation avec les ressources disponibles

Le projet est dimensionné pour [N] étudiants à environ [H] heures par semaine, soit environ [N × H × nombre de semaines] heures au total (à compléter selon le volume horaire officiel du PER).

Ressources informatiques. Les données sont légères : environ 40 000 adultes et quelques centaines de variables tiennent en mémoire sur un ordinateur portable. PostgreSQL tourne en local, et tous les outils sont libres : Python, pandas, scikit-learn, LightGBM, DoWhy, EconML, Streamlit, Docker. Le code est versionné sur GitHub. Seules les forêts causales sont coûteuses ; elles seront limitées aux couples retenus pour le démonstrateur. Google Colab sert de solution de repli si un calcul dépasse les capacités d'un portable.

Dimensionnement du périmètre. Le cœur du projet porte sur les témoins positifs et négatifs (environ 15 couples). L'extension à 30–50 classes × 15 biomarqueurs est un objectif secondaire, automatisé par le pipeline.

Risque	Impact	Parade
Effectifs trop faibles pour certaines classes	Estimations instables	Classes retenues seulement au-dessus d'un seuil d'exposés ; regroupement en classes plus larges
Violation de la positivité	Poids extrêmes, biais	Diagnostic des scores de propension, troncature, restriction de la population

Risque	Impact	Parade
Confusion non mesurée (sévérité, doses)	Biais résiduel	Témoins négatifs, E-value, discussion explicite
Hétérogénéité entre cycles	Biais de mesure	Effet du cycle en covariable, recalibration de la créatinine
Temps de calcul des forêts causales	Retard	Calcul hors ligne, modèles sauvegardés et chargés par le démonstrateur

8. Description du démonstrateur final

Le démonstrateur est une application web Streamlit, livrée avec un `docker-compose` qui lance PostgreSQL et l'application en une commande.

Page « Patient » (usage métier).

- *Entrées* : âge, sexe, IMC, pathologies (diabète, HTA, insuffisance rénale…), liste des traitements, biomarqueur et valeur observée.
- *Sorties*, pour chaque traitement du patient : effet estimé sur le biomarqueur avec son intervalle de confiance, valeur attendue sans ce traitement, part de l'écart à la normale attribuable, et niveau de confiance (effectif, E-value, résultat des réfutations).
- Un graphique en barres montre la contribution de chaque traitement, et un bandeau rappelle qu'il s'agit d'un effet moyen pour des profils similaires.

Page « Méthode » (transparence).

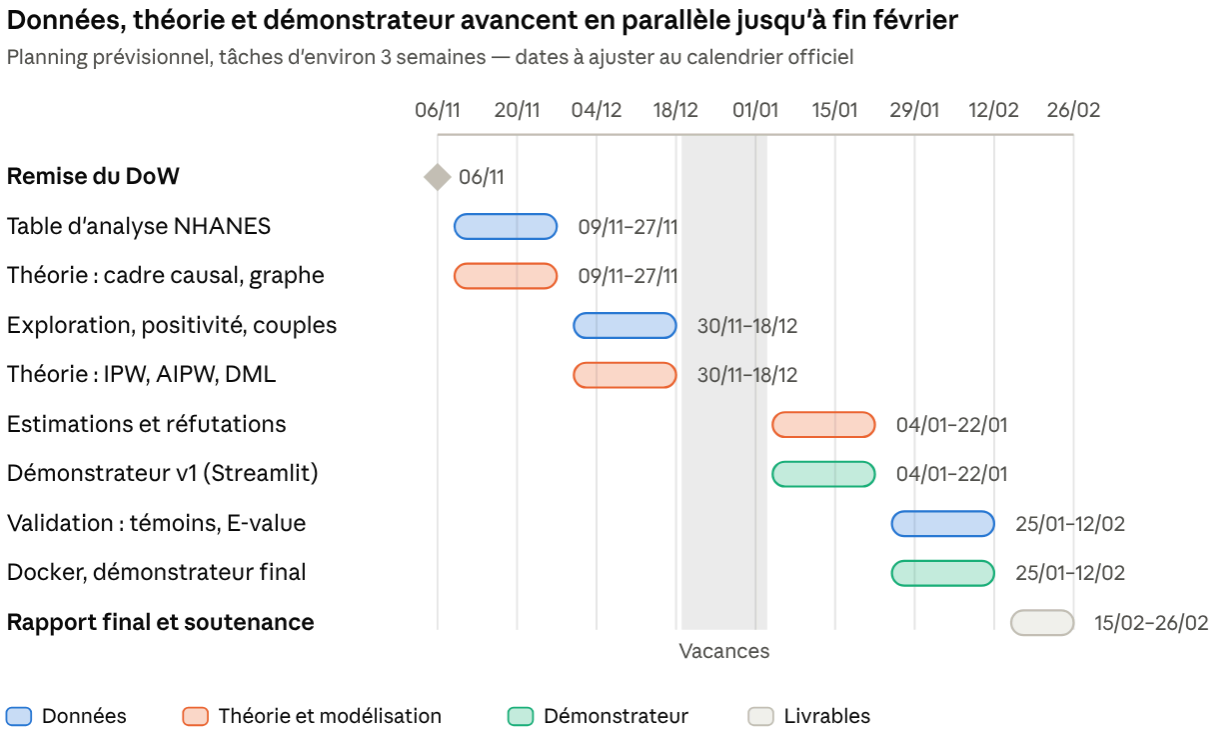
- Le graphe causal utilisé pour le couple choisi.
- La comparaison entre corrélation brute et effet ajusté, qui met en évidence la confusion par indication.
- Les diagnostics : distribution des scores de propension, équilibre des covariables après pondération.

Page « Validation ». Les résultats sur les témoins positifs et négatifs, sous forme de *forest plot*.

Les modèles sont entraînés hors ligne et sauvegardés ; l'application ne fait que les charger, ce qui garantit une réponse en quelques secondes.

9. Planning des tâches à réaliser

Le projet se déroule pendant les semaines de cours, avec des tâches d'environ 3 semaines menées en parallèle par sous-groupe.



planning prévisionnel · 9 tâches, novembre 2026 à février 2027

Répartition : 3 tâches sur les données (table d'analyse, exploration, validation), 3 sur l'étude théorique et la modélisation, 2 sur le démonstrateur, plus le rapport final. Les dates sont à caler sur le calendrier officiel du PER [à confirmer], notamment s'il comporte une période à temps plein.

10. Bibliographie

Références à vérifier (auteurs, années, revues) avant la version finale.

Inférence causale

- Rubin D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*.
- Rosenbaum P. R., Rubin D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*.
- Pearl J. (2009). *Causality: Models, Reasoning and Inference*, 2e éd. Cambridge University Press.
- Hernán M. A., Robins J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.

- Hernán M. A., Robins J. M. (2016). Using big data to emulate a target trial when a randomized trial is not available. *American Journal of Epidemiology*.
- Chernozhukov V. et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*.
- Wager S., Athey S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*.
- Künzel S. R. et al. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *PNAS*.
- VanderWeele T. J., Ding P. (2017). Sensitivity analysis in observational research: introducing the E-value. *Annals of Internal Medicine*.
- Lipsitch M., Tchetgen Tchetgen E., Cohen T. (2010). Negative controls: a tool for detecting confounding and bias in observational studies. *Epidemiology*.

Pharmacovigilance et pharmaco-épidémiologie

- Evans S. J. W., Waller P. C., Davis S. (2001). Use of proportional reporting ratios (PRRs) for signal generation from spontaneous adverse drug reaction reports. *Pharmacoepidemiology and Drug Safety*.
- Bate A. et al. (1998). A Bayesian neural network method for adverse drug reaction signal generation. *European Journal of Clinical Pharmacology*.
- DuMouchel W. (1999). Bayesian data mining in large frequency tables, with an application to the FDA spontaneous reporting system. *The American Statistician*.
- Naranjo C. A. et al. (1981). A method for estimating the probability of adverse drug reactions. *Clinical Pharmacology & Therapeutics*.
- Schuemie M. J. et al. (2014). Interpreting observational studies: why empirical calibration is needed to correct p-values. *Statistics in Medicine*.
- Schuemie M. J. et al. (2019). Comprehensive comparative effectiveness and safety of first-line antihypertensive drug classes (LEGEND-HTN). *The Lancet*.
- Reinstatler L. et al. (2012). Association of biochemical B12 deficiency with metformin therapy and vitamin B12 supplements: NHANES 1999–2006. *Diabetes Care*.

Données et outils

- CDC / NCHS. National Health and Nutrition Examination Survey, cycles 2005–2018 : données, documentation et *Analytic Guidelines*.
- Sharma A., Kiciman E. (2020). DoWhy: An end-to-end library for causal inference. arXiv.
- Battocchi K. et al. (2019). EconML: A Python package for ML-based heterogeneous treatment effects estimation. Microsoft Research, GitHub.